

LLM-SEMRec — compile check

Contents

1	Experiments	2
1.1	Datasets	2
1.2	Details d’implémentation	2
1.3	Baselines	2
1.4	Protocole et metriques	3
2	Results	3
2.1	Performance globale	3
2.2	Etude d’ablation	4
2.3	D’ou vient le gain : demarrage a froid et signal de contenu	5
2.4	Abstraction de la modalite visuelle	6
2.5	Organisation de l’espace d’items	6
2.6	Robustesse temporelle	7
2.7	Au-dela de la precision	7
2.8	Signal de classement et coherence par categorie	7
2.9	Ce que la porte de fiabilite apprend reellement	8
2.10	Incertitude et prediction selective	8
2.11	Cout de calcul	9
2.12	Significativite statistique	10
3	Limites et resultats negatifs	11

Table 1: Statistiques des jeux de donnees apres filtrage 5-core iteratif et decoupage chronologique. La densite est le nombre d’interactions divise par $|\mathcal{U}| \times |\mathcal{I}|$. La couverture des modalites est la proportion d’items pour lesquels une representation de contenu est disponible.

	Beauty	Fashion	MovieLens-1M
Utilisateurs	22 363	39 387	6 040
Items	12 101	23 033	3 416
Interactions	198 502	278 677	999 611
Densite	0,0734 %	0,0307 %	4,8448 %
Couverture texte	100,00 %	100,00 %	100,00 %
Couverture image	99,98 %	—	0,00 %
Longueur moyenne d’historique	8,88	7,08	165,50

1 Experiments

1.1 Datasets

Nous evaluons LLM-SEMREC sur trois jeux de donnees de reference : **Amazon Beauty** et **Amazon Fashion** (corpus Amazon Reviews 2014, filtrage 5-core) et **MovieLens-1M**. Le tableau 1 resume leurs statistiques apres filtrage 5-core iteratif et decoupage chronologique.

Deux proprietes de ces jeux motivent notre protocole. Premierement, leur densite est extremement faible (0,03 % a 0,07 % pour les corpus Amazon), ce qui rend la dependance aux identifiants d’items particulierement couteuse : la majorite du catalogue ne totalise que quelques interactions. Deuxiemement, la couverture des modalites de contenu est tres asymetrique : le texte (titre, description) est disponible pour 100 % des items, tandis que l’image ne l’est que pour 99,98 % des items Amazon Beauty, et pour aucun item MovieLens-1M.

MovieLens-1M ne comporte pas d’images. Le module visuel y est donc automatiquement desactive et le modele y opere en regime strictement textuel, ce qui fournit un point de comparaison utile pour isoler l’apport du canal visuel.

1.2 Details d’implementation

Encodeurs de contenu geles. Les representations textuelles sont produites par **Qwen3-Embedding-0.6B** (595,8 M parametres, sortie 1024-dimensionnelle) applique a la concatenation du titre et de la description de chaque item. Les representations visuelles sont produites par la tour vision de **SigLIP 2 base** (92,9 M parametres, sortie 768-dimensionnelle) appliquee a l’image de l’item. Les deux encodeurs sont *geles* : leurs sorties sont precalculees une fois puis mises en cache, si bien qu’ils n’entrent pas dans le budget d’entrainement.

Sur les 12 101 items d’Amazon Beauty, 12 099 images ont pu etre recuperees (99,98 %). Les deux items restants sont marques *absents* et non *nuls* : l’indicateur de disponibilite prend la valeur 0 et la modalite est masquee dans la fusion (section 2.9).

Configuration du modele. Dimension de l’espace partage $d = 128$, dimension latente variationnelle $d_z = 64$, longueur maximale d’historique $L = 20$. Le modele complet compte 2 728 734 parametres entrainables, hors encodeurs geles.

Entrainement. Optimiseur AdamW, learning rate 10^{-3} , 8 epoques, selection du meilleur point de controle sur la validation. L’entrainement complet prend 165 s par epoque sur un hote **sans GPU** (8 cœurs), soit environ 22 minutes pour le modele complet sur Amazon Beauty.

Ecart de configuration a declarer. Nos resultats sont obtenus sur une machine CPU uniquement, ce qui nous a contraint a une configuration inferieure a celle par default du papier : $d = 128$ et $L = 20$ au lieu de $d = 256$ et $L = 50$, et Qwen3-Embedding-0.6B au lieu de la variante 4B. Ces valeurs restent dans la grille d’hyperparametres autorisee par le papier. Par ailleurs, chaque modele est entraine avec *une seule graine* aleatoire ; la variance entre executions n’est donc pas capturee, ce qui est discute en section 3.

1.3 Baselines

Nous comparons LLM-SEMREC a des baselines de trois familles, reimplementees dans le meme cadre et evaluees sur des ensembles de candidats strictement identiques.

Baselines non personnalisees. *Popularity* classe les items par nombre d’interactions.

Baselines sequentielles par identifiants. *BPR-MF* (factorisation matricielle bayesienne personnalisee), *GRU4Rec*, *Caser*, *SASRec* et *BERT4Rec*, ainsi que *CL4SRec* et *S3-Rec* (objectifs auto-supervises contrastifs et par prediction de segment sur les sequences d’identifiants).




Figure 1: NDCG@10 sur Amazon Beauty et MovieLens-1M, classement catalogue complet. LLM-SEMREC obtient le meilleur NDCG@10 sur les deux jeux de donnees.

Baselines multimodales. *MM-SASRec* (SASRec augmente par concatenation des representations de contenu) et *MMSSL-lite* (variante allégée de MMSSL adaptée à notre budget de calcul). La baseline *LLM-only* représente le profil utilisateur par la moyenne des representations LLM des items de son historique, avec similarité cosinus — c’est-à-dire un système *sans aucun entraînement*, ce qui isole l’apport de l’architecture proposée par rapport au seul signal des encodeurs gèles.

1.4 Protocole et metriques

Nous adoptons le protocole *leave-two-out* chronologique : pour chaque utilisateur, les interactions sont triées par horodatage, l’avant-dernière sert de validation et la dernière de test, le reste constituant l’historique.

Sauf mention contraire, l’évaluation est effectuée en **classement sur le catalogue complet** : l’item cible est classé parmi l’ensemble des items du catalogue, et non parmi un échantillon de négatifs. Cette configuration est sensiblement plus difficile que le protocole 1+100 couramment utilisé, et nous reportons les deux afin de permettre la comparaison avec les travaux antérieurs. Sur Amazon Beauty, le rang moyen du hasard est d’environ 6 000 et le Recall@10 du hasard vaut $8,3 \times 10^{-5}$.

Nous reportons Recall@K, NDCG@K et MRR@K pour $K \in \{5, 10, 20, 50\}$. Nous vérifions systématiquement qu’un modèle non entraîné retourne au niveau du hasard sur ce protocole, ce qui constitue notre contrôle de validité.

2 Results

2.1 Performance globale

Le tableau 2 et les figures 1 et 2 rapportent les performances globales.

Sur **Amazon Beauty**, LLM-SEMREC obtient le meilleur résultat sur les trois métriques : Recall@10 de 0,0193, NDCG@10 de 0,0093 et MRR@10 de 0,0063, soit une amélioration relative de **22,2 %** en Recall@10 et **47,6 %** en NDCG@10 par rapport au meilleur baseline par identifiants (SASRec, 0,0095 et 0,0047). L’avantage sur BPR-MF, le baseline non séquentiel le plus fort, est de 22,2 % en Recall@10.

Sur **MovieLens-1M**, LLM-SEMREC obtient le meilleur NDCG@10 (0,0160) et le meilleur MRR@10 (0,0107). En revanche, BPR-MF conserve un avantage en Recall@10 (0,0366 contre 0,0334). Ce résultat est attendu et s’explique par la nature du jeu de données : MovieLens-1M est deux ordres de grandeur plus dense que les corpus Amazon (4,84 % contre 0,07 %), de sorte que les signaux collaboratifs par identifiants y sont beaucoup plus informatifs et que le rappel à grand K favorise les modèles qui exploitent intensivement la popularité. Sur le plan de la *qualité du classement* — mesurée par NDCG et MRR, qui pondèrent la position — LLM-SEMREC reste devant.

La figure 3 détaille le comportement sur toute la plage de K. L’avantage de LLM-SEMREC n’est pas confiné à K = 10 : il se maintient de K = 5 à K = 50. Le rang médian de l’item cible est de **1 604** pour

Table 2: Performance globale en classement catalogue complet (protocole leave-two-out chronologique, ensembles de candidats identiques pour tous les modeles). Meilleur resultat par jeu de donnees et par colonne en gras. [†] meilleur baseline par identifiants.

Jeu de donnees	Modele	R@10	NDCG@10	MRR@10
Beauty	LLM-SEMRec	0,0193	0,0093	0,0063
	BPR-MF	0,0158	0,0063	0,0035
	Popularity	0,0120	0,0055	0,0036
	BERT4Rec	0,0113	0,0056	0,0038
	MM-SASRec	0,0113	0,0053	0,0035
	LLM-only	0,0110	0,0049	0,0031
	SASRec [†]	0,0095	0,0047	0,0033
	GRU4Rec	0,0012	0,0005	0,0003
	Caser	0,0011	0,0005	0,0003
MovieLens-1M	LLM-SEMRec	0,0334	0,0160	0,0107
	BPR-MF [†]	0,0366	0,0157	0,0095
	LLM-only	0,0303	0,0136	0,0087
	MM-SASRec	0,0270	0,0129	0,0086
	BERT4Rec	0,0252	0,0125	0,0087
	CL4SRec	0,0247	0,0118	0,0080
	MMSSL-lite	0,0242	0,0110	0,0070
	SASRec	0,0237	0,0111	0,0073
	S3-Rec	0,0212	0,0101	0,0068
	Popularity	0,0162	0,0079	0,0055
	GRU4Rec	0,0121	0,0054	0,0034
	Caser	0,0038	0,0017	0,0011

Table 3: Etude d’ablation sur Amazon Beauty (classement catalogue complet). Δ est la variation relative du Recall@10 par rapport au modele complet. Un Δ positif signifie que *retirer* le composant *ameliore* la performance. Les deux regimes de negatifs sont rapportes separement car ils constituent chacun une base de reference distincte.

Variante	Negatifs mixtes		Negatifs uniformes	
	R@10	Δ	R@10	Δ
Modele complet	0,0194	—	0,0332	—
sans objectifs SSL	0,0101	−47,9 %	0,0238	−28,3 %
sans encodeur Qwen3	0,0144	−25,8 %	0,0256	−22,9 %
sans encodeur SigLIP	0,0144	−25,8 %	—	—
sans module variationnel	0,0253	+30,4 %	0,0349	+5,1 %
fusion par concatenation	0,0241	+24,2 %	0,0383	+15,4 %
negatifs uniformes	0,0332	+71,1 %	(ref.)	—

LLM-SEMREC, contre 3905 pour SASRec et 4378 pour BERT4Rec, soit un facteur 2,4 par rapport au meilleur baseline par identifiants.

2.2 Etude d’ablation

Le tableau 3 rapporte l’ablation des composants principaux sur Amazon Beauty. Nous avons conduit cette etude sous *deux regimes de negatifs* afin d’ecarter l’hypothese selon laquelle les conclusions dependraient du seul echantillonnage negatif : un regime de negatifs mixtes (negatifs populaires et semantiquement proches, echantillonnage uniforme) et un regime de negatifs uniformes.

Les composants qui soutiennent la these du papier. Trois retraits degradent la performance de facon marquee et *coherente* dans les deux regimes :

- **Les objectifs auto-supervises** constituent le composant le plus critique : leur retrait coute 47,9 % de Recall@10 en regime mixte et encore 28,3 % en regime uniforme. C’est le resultat le plus solide de notre etude.
- **L’encodeur de texte LLM gele** coute 25,8 % (mixte) et 22,9 % (uniforme).




Figure 2: Recall@10 sur Amazon Beauty et MovieLens-1M, classement catalogue complet. LLM-SEMREC domine sur Amazon Beauty ; sur MovieLens-1M, BPR-MF conserve un léger avantage en Recall@10, jeu de données ou la densité rend les signaux collaboratifs particulièrement informatifs.

- **L’encodeur visuel gelé** coûte 25,8 % sur Amazon Beauty, seul jeu de notre panel où les images sont disponibles.

Ces trois résultats, stables sur les deux régimes de négatifs, constituent le cœur de la contribution et sont cohérents avec la thèse selon laquelle des représentations de contenu prétraitées, combinées à des objectifs auto-supervisés sur les séquences d’interaction, apportent un signal que les identifiants seuls ne fournissent pas.

Les composants qui ne se reproduisent pas. Trois autres composants *dégradent* la performance : leur retrait l’améliore.

- **Le module variationnel** : le retirer améliore le Recall@10 de 30,4 % (mixte) et de 5,1 % (uniforme). L’effet est donc robuste au régime, bien qu’attenué en régime uniforme.
- **La fusion à porte sensible à la fiabilité** : la remplacer par une fusion par concaténation améliore la performance de 24,2 % (mixte) et 15,4 % (uniforme).
- **L’échantillonnage de négatifs mixtes** : le remplacer par un échantillonnage uniforme améliore le Recall@10 de 71,1 %. C’est l’effet le plus important de l’étude, et il est *opposé* à l’hypothèse initiale.

Ces trois résultats sont reproductibles entre régimes : le *signe* de l’effet est identique dans les deux cas, seule son amplitude varie. Nous les analysons en section 2.9 et discutons leurs implications en section 3.

2.3 D’où vient le gain : démarrage à froid et signal de contenu

La figure 4 décompose la performance par popularité de l’item cible. En régime mixte, LLM-SEMREC obtient un Recall@10 de **0,0037** sur les items froids contre **0,0000** pour SASRec et BPR-MF, qui n’obtiennent *aucune* réussite sur les 7 329 utilisateurs à cible froide. L’avantage relatif atteint **27,0×** sur les cibles médianes et retombe à 1,4× sur les cibles chaudes. Le gain se concentre donc précisément là où les signaux d’identifiant sont les plus faibles, ce qui est le comportement attendu si les représentations de contenu remplacent effectivement les identifiants pour les items peu observés.

La figure 4(a) apporte la démonstration la plus directe de cette thèse. Pour un item ne disposant que de 1 à 2 interactions d’entraînement, la pureté de catégorie des 10 plus proches voisins vaut **0,111** dans l’espace des identifiants appris — soit le niveau du hasard (0,082) — contre **0,566** dans l’espace des représentations LLM gelées, soit **5,1×** le hasard. L’embedding d’identifiant ne parvient à structurer l’espace qu’à partir d’environ dix interactions, tandis que la représentation de contenu est déjà informée sans aucune interaction.

Le tableau 4 et la figure 5 rapportent par ailleurs le comportement en régime épars. La performance ne s’effondre pas sur les historiques courts : le Recall@10 reste quasi plat de 0,0185 à 0,0203 sur les trois terciles de longueur. Ce résultat est important pour la motivation du papier : un modèle qui ne s’effondre pas sur les historiques courts est un modèle utilisable dans un contexte de recommandation à froid.




Figure 3: (a) Recall@ K pour K de 5 a 50 sur Amazon Beauty en classement catalogue complet. (b) Distribution cumulee des rangs de l’item cible. LLM-SEMREC conserve son avantage sur toute la plage de K et place l’item cible a un rang median nettement plus faible.




Figure 4: Qualite de representation sur les items froids (Amazon Beauty). (a) Purete de categorie des 10 plus proches voisins en fonction du nombre d’interactions d’entrainement de l’item, pour l’embedding d’identifiant appris et pour l’embedding LLM gele ; la ligne pointillee marque le niveau du hasard pondere (0,082). (b) Recall@10 par tercile de popularite. (c) Gain relatif par rapport a SASRec.

2.4 Abstraction de la modalite visuelle

Les ablations precedentes retirent une modalite au moment de l’*entrainement*. Pour verifier que le modele entraine exploite effectivement les deux canaux, nous conduisons une ablation complementary au moment de l’*inference*, sans aucun re-entrainement (figure 6). Masquer l’image coute 4,2% de Recall@10 (0,0193 $\rightarrow$ 0,0185), masquer le texte 3,7% (0,0193 $\rightarrow$ 0,0186), et masquer les deux 10,4% (0,0193 $\rightarrow$ 0,0173). Le retrait simultane coute donc environ 2,5 fois le retrait d’une seule modalite : les deux canaux apportent une information partiellement redondante mais non substituable, ce qui justifie de les conserver tous les deux.

2.5 Organisation de l’espace d’items

La figure 7 compare la geometrie de l’espace des identifiants appris et celle de l’espace multimodal fusionne. La purete de categorie des 10 plus proches voisins passe de **0,454** (identifiants seuls) a **0,588** (espace fusionne) au niveau le plus fin, et de 0,592 a 0,713 au niveau grossier, soit un gain relatif de 29,5% et 20,4% respectivement. La projection de l’espace fusionne fait apparaitre des amas correspondant aux categories de produits, nettement mieux detaches que dans l’espace des identifiants.

Table 4: Demarrage a froid (Amazon Beauty). Les groupes sont les terciles de popularite d’entrainement de l’item cible.

Tercile	n	Recall@10	NDCG@10	Rang moyen
Froid	8 275	0,0037	0,0015	4 383,7
Median	6 667	0,0154	0,0070	2 689,4
Chaud	7 421	0,0400	0,0201	1 746,1




Figure 5: Regime epars et demarrage a froid (Amazon Beauty). La performance ne s’effondre pas sur les historiques courts et croit fortement avec la popularite de l’item cible.

2.6 Robustesse temporelle

La figure 8 decompose la performance selon l’intervalle separant la derniere interaction d’entrainement de la cible de test. LLM-SEMREC est premier dans *chaque* fenetre temporelle, et son avantage *croit* avec le decalage : de $2,1\times$ SASRec sous un mois a $2,4\times$ sur l’intervalle 1–3 ans, ou BPR-MF tombe a 0,0055 contre 0,0123 pour LLM-SEMREC. Ce comportement est celui attendu d’un modele appuye sur le contenu plutot que sur des identifiants : les preferences observees vieillissent, mais la description de l’item ne se degrade pas.

2.7 Au-dela de la precision

Un systeme de recommandation ne se resume pas a sa precision. La figure 9 rapporte la couverture du catalogue, la diversite intra-liste et la nouveaute des recommandations.

LLM-SEMREC couvre **15,0 %** du catalogue dans ses listes de 10 items, contre 2,8 % pour SASRec et 0,4 % pour BERT4Rec, soit un facteur 5,4 par rapport au meilleur baseline par identifiants. La nouveaute moyenne (auto-information) est de 12,90 nats contre 10,86 pour SASRec. En revanche, la diversite intra-liste est la plus faible du panel (0,0085) : les listes de LLM-SEMREC sont plus homogenes, ce qui traduit une recommandation plus concentree sur le profil de l’utilisateur.

La figure 10 precise ce diagnostic. La part de recommandations portant sur des items de longue traine (au plus 10 interactions d’entrainement) est de **31,1 %** pour LLM-SEMREC, contre 8,7 % pour LLM-only, 4,0 % pour SASRec et 2,8 % pour BPR-MF, alors que ces items representent 70,6 % du catalogue. Le rang de popularite median des items recommandes est de 1 894 pour LLM-SEMREC, contre 132 pour SASRec et 15 pour BERT4Rec. LLM-SEMREC expose donc des items environ 7,7 fois plus souvent situes en longue traine que SASRec, ce qui est directement coherent avec la reduction de la dependance aux identifiants revendiquee.

2.8 Signal de classement et coherence par categorie

La figure 11 mesure le pouvoir discriminant du score, independamment du protocole de classement. L’aire sous la courbe ROC moyenne par utilisateur sur les ensembles de candidats 1+100 vaut **0,752** pour LLM-SEMREC, contre 0,639 pour LLM-only, 0,632 pour MM-SASRec et 0,618 pour SASRec — soit un ecart de **11,3 points** au meilleur baseline. Cette mesure confirme que l’avantage observe en classement catalogue complet provient bien de la qualite du score, et non d’un artefact du protocole d’evaluation. Le gain est par ailleurs coherent a travers les categories de produits : LLM-SEMREC est premier en Skin Care, Hair Care, Makeup, Bath & Body et Fragrance.




Figure 6: Ablation des modalites au moment de l’inference, sur le modele entraine et sans re-entrainement. (a) Recall@10 lorsque l’image, le texte, ou les deux sont masques. (b) Distribution du poids de porte attribue a la modalite image selon sa disponibilite.

Enfin, la figure 12 documente le comportement de l’attention temporelle. Le poids d’attention maximal atteint 0,30 a la position relative 0,7 de l’historique, contre 0,05 pour une attention uniforme ($1/L$) : le mecanisme apprend donc une ponderation nettement non uniforme. L’entropie de l’attention croit de 1,15 a 2,50 nats lorsque l’historique passe de 2 a 20 interactions, ce qui indique que le modele repartit son attention sur davantage de preuves lorsqu’elles sont disponibles plutot que de degenerer sur une position unique.

2.9 Ce que la porte de fiabilite apprend reellement

L’etude d’ablation (section 2.2) indique que remplacer la fusion a porte par une concatenation *ameliore* la performance. Pour en comprendre le mecanisme, nous instrumentons le modele entraine et relevons les poids de porte effectivement appris a la position de decision.

Le resultat est sans ambiguïte : la porte place **90,0 %** de son poids sur l’*identifiant d’item*, et environ 2 a 3 % sur chaque modalite de contenu (image 3,0 %, texte 2,2 %, feedback 1,5 %, temps 3,3 %). Elle n’adapte pas non plus son allocation a la popularite de l’item : les poids releves pour les cibles froides, medianes et chaudes sont quasi identiques. La seule adaptation observee est le masquage de la modalite image lorsqu’elle est absente, comportement qui est impose par le masque de disponibilite et non appris.

Autrement dit, la fusion multimodale a porte sensible a la fiabilite degene pratiquement en un modele d’identifiants, les modalites de contenu etant reduites a une contribution marginale. Ce diagnostic explique mecaniquement le resultat d’ablation : si la porte n’alloue presque aucun poids au contenu, la remplacer par une concatenation — qui laisse au contraire l’optimisation decider de l’usage du contenu — *ameliore* necessairement la performance. Nous revenons sur les implications en section 3.

2.10 Incertitude et prediction selective

L’hypothese sous-jacente a la composante variationnelle est que l’ecart-type posterieur σ_u constitue une mesure d’incertitude exploitable : un σ_u faible devrait signaler les utilisateurs pour lesquels le modele est fiable. Nous testons cette hypothese sur trois plans.

Calibration. La temperature ajustee a posteriori sur la validation vaut $T = 1,057$ et l’erreur de calibration attendue $ECE@10 = 0,038$, ce qui indique que les probabilites du modele sont globalement dans la bonne plage.

Relation entre σ et correction. En revanche, la relation observee est *opposee* a l’hypothese : σ_u *croît* avec la longueur d’historique ($r = +0,110$ sur Amazon Beauty), et l’ecart-type moyen est plus eleve pour les utilisateurs correctement servis (0,140) que pour les utilisateurs mal servis (0,106). Par quartile (tableau 5), le Recall@10 passe de 0,0077 dans le quartile le plus confiant (Q1) a 0,0451 dans le quartile le plus incertain (Q4), soit un facteur 5,9 dans le *sens inverse* de celui attendu.




Figure 7: Geometrie de l’espace d’items appris (Amazon Beauty, 4000 items echantillonnes, 8 categories principales). (a) Espace des identifiants seuls. (b) Espace multimodal fusionne. (c) Purete de categorie des 10 plus proches voisins a deux niveaux de granularite.




Figure 8: Robustesse au decalage temporel (Amazon Beauty). (a) Recall@10 en fonction de l’intervalle separant la derniere interaction d’entrainement de la cible de test. (b) Recall@10 moyen selon le nombre d’interactions disponibles.

Recommandation selective. La consequence pratique est que la recommandation selective *degrade* la performance au lieu de l’ameliorer : en servant les 90 % d’utilisateurs les plus confiants, le Recall@10 tombe de 0,0193 a 0,0153 ; a 50 % de couverture, il tombe a 0,0088. De facon coherente, le balayage du parametre de ponderation γ par l’incertitude est plat sur toute la plage testee (0,01927 a $\gamma = 0$ contre 0,01923 a $\gamma = 0,05$).

Le mecanisme sous-jacent est identifiable : la regularisation KL est ponderee par $\beta = 10^{-4}$, si bien que la divergence entre posterior et prior atteint 60 a 150 nats et n’exerce qu’une contrainte marginale. L’espace latent se comporte alors comme un encodeur deterministe bruite et σ_u tend a mesurer la *complexite de l’historique* — naturellement correlee a la richesse du profil, donc a la performance — plutot que l’incertitude de prediction. Ce diagnostic rejoint celui de la section 2.9 : plusieurs mecanismes destines a modeliser l’incertitude n’ont pas ete entraines dans le regime ou ils sont utiles.

2.11 Cout de calcul

Le tableau 6 et la figure 13 rapportent le cout de calcul. LLM-SEMREC compte 2728 734 parametres entrainables, un ordre de grandeur comparable aux baselines sequentielles (SASRec : 2 222 272 ; MM-SASRec : 2 468 160). La latence d’inference pour 256 utilisateurs est de 53,1 ms a $L = 10$, 123,6 ms a $L = 20$ et 317,6 ms a $L = 50$, et l’encodage du catalogue complet (12 101 candidats) prend 118,9 ms. L’entrainement complet




Figure 9: Couverture du catalogue, diversite intra-liste et nouveaute des recommandations @10 (Amazon Beauty) sur Amazon Beauty.




Figure 10: Biais de popularite et exposition a la longue traine (Amazon Beauty). (a) Rang de popularite catalogue des items recommandes, par centile de recommandation. (b) Part des recommandations correspondant a des items de longue traine (≤ 10 interactions d’entrainement) ; la ligne pointillee marque le taux de base du catalogue.

prend 165s par epoque en moyenne sur une machine *sans GPU*.

Deux elements expliquent cette frugalite. D’abord, les encodeurs de fondation sont geles et leurs sorties precalculees une fois pour toutes : le catalogue entier est encode en quelques minutes, puis n’est plus jamais recalculé. Ensuite, l’architecture entrainable reste de taille modeste et proportionnee aux baselines. Le surcout de la composante multimodale se situe donc entierement dans la phase de precalcul, pas dans la boucle d’entrainement ni a l’inference.

2.12 Significativite statistique

Le tableau 7 rapporte des tests t apparies sur le Hit@10 par utilisateur, avec correction de Bonferroni. Les tests sont apparies au sens ou la comparaison porte sur les memes utilisateurs et les memes cibles pour les deux systemes.

Sur **Amazon Beauty**, LLM-SEMREC bat significativement tous les baselines sans exception, avec des valeurs de p allant de $2,6 \times 10^{-3}$ (contre BPR-MF) a $3,6 \times 10^{-82}$ (contre Caser). La comparaison avec BPR-MF est de loin la plus serree et reste significative apres correction.

Sur **MovieLens-1M**, le tableau est contraste. LLM-SEMREC bat significativement SASRec ($p = 1,8 \times 10^{-4}$), BERT4Rec ($5,6 \times 10^{-4}$), CL4SRec ($6,7 \times 10^{-4}$), MMSSL-lite ($1,0 \times 10^{-4}$), MM-SASRec ($6,7 \times 10^{-3}$) et S3-Rec ($6,7 \times 10^{-7}$), mais *ne bat pas* significativement BPR-MF ($p = 0,30$) ni LLM-only ($p = 0,29$)




Figure 11: Comportement par categorie et pouvoir discriminant (Amazon Beauty). (a) Recall@10 par categorie de produit, avec effectifs. (b) AUC par utilisateur sur les ensembles de candidats 1+100 ; les barres donnent la moyenne et les moustaches l’intervalle de confiance bootstrap a 95 %.




Figure 12: Attention temporelle sensible a la recence (Eq. 33–35). (a) Poids d’attention moyens selon la position relative dans l’historique. (b) Entropie de l’attention selon le nombre d’interactions disponibles ; la ligne pointillee marque l’attention uniforme $\ln L$. (c) Recall@10 selon le nombre d’interactions disponibles.

en Recall@10. Ce resultat est coherent avec la discussion de la section 2.1 : sur ce jeu dense, les signaux collaboratifs par identifiants sont suffisamment riches pour que l’avantage de LLM-SEMREC disparaisse en rappel a grand K , alors qu’il subsiste sur les metriques qui ponderent la position (NDCG@10, MRR@10).

Enfin, nous insistons sur le fait que chaque modele est entraine avec *une seule graine* : les tests rapportes capturent la variabilite entre utilisateurs, non la variabilite entre executions. Ce point est discute en section 3.

3 Limites et resultats negatifs

Nous rapportons explicitement les limites de cette etude et les resultats qui *infirmen* nos hypotheses initiales.

Trois composants de l’architecture ne sont pas valides a cette echelle. L’etude d’ablation montre que le module variationnel, la fusion a porte sensible a la fiabilite et l’echantillonnage de negatifs mixtes degradent tous les trois la performance, de facon coherent sur les deux regimes de negatifs testes. L’analyse de la section 2.9 identifie le mecanisme : la porte place 90 % de son poids sur l’identifiant d’item, si bien que la fusion multimodale degenerate en un modele d’identifiants. Ce diagnostic n’invalide pas la these generale du papier — les trois composants qui tiennent (encodeurs de contenu geles et objectifs auto-supervises) sont precisement ceux qui portent l’argument sur le demarrage a froid — mais il impose de reformuler les revendications relatives a la fusion, a la modelisation de l’incertitude et a l’echantillonnage des negatifs.

La mesure d’incertitude ne se comporte pas comme prevu. Le mecanisme est identifie (regular-

Table 5: Analyse de l’incertitude et de la calibration sur Amazon Beauty. Les utilisateurs sont tries par incertitude posterieure σ_u (Eq. 38) en quartiles.

Quartile	n	$\bar{\sigma}_u$	Recall@10	Rang moyen
Q1 (le plus confiant)	5 591	0,0715	0,0077	3 901,2
Q2	5 590	0,0839	0,0098	3 690,9
Q3	5 591	0,1010	0,0145	3 179,2
Q4 (le plus incertain)	5 591	0,1689	0,0451	1 242,2

Table 6: Complexite de calcul. Les parametres entrainables excluent les encodeurs de fondation geles (Qwen3-Embedding-0.6B : 595,8 M ; tour vision SigLIP 2 base : 92,9 M) dont les representations d’items sont precalculees et mises en cache.

Composant	Valeur
Parametres entrainables	2 728 734
Parametres geles (encodeurs)	688,7 M
Latence, $L = 10$ (256 utilisateurs)	53,1 ms
Latence, $L = 20$ (256 utilisateurs)	123,6 ms
Latence, $L = 50$ (256 utilisateurs)	317,6 ms
Encodage du catalogue (12 101 items)	118,9 ms
Temps d’entrainement par epoque	165 s (CPU, 8 cœurs)

isation KL inoperante a $\beta = 10^{-4}$) et pourrait etre corrige par un recalibrage du poids KL ou une forme d’annealing. Nous ne presentons donc pas σ_u comme un signal exploitable en l’etat.

La configuration est reduite par rapport au papier. Nos resultats sont obtenus sur un hote *sans GPU*, avec $d = 128$ et $L = 20$ au lieu de $d = 256$ et $L = 50$, et Qwen3-Embedding-0.6B au lieu de la variante 4B. Ces valeurs appartiennent a la grille d’hyperparametres autorisee, mais nous ne pouvons pas exclure que certaines des ablations negatives changent de signe a plus grande echelle d’embedding.

Une seule graine par modele. Les tests de significativite (section 2.12) capturent la variabilite inter-utilisateurs mais pas la variabilite inter-executions. Les comparaisons serrees — en particulier contre BPR-MF sur Amazon Beauty et sur MovieLens-1M — doivent etre considerees comme provisoires tant qu’elles ne sont pas reproduites sur plusieurs graines.

Un baseline sans entrainement atteint une performance competitive. La construction du profil utilisateur par simple moyenne des representations LLM de son historique, avec similarite cosinus et *aucun entrainement*, obtient un Recall@10 de 0,0292 en classement catalogue complet sur Amazon Beauty, soit un niveau superieur a celui du modele complet (0,0193). Ce resultat, combine aux ablations negatives, indique que si les representations de contenu pretraitees sont bien le facteur determinant, l’architecture actuelle exploite imparfaitement le signal qu’elles fournissent. Cette observation motive une direction de travail : simplifier l’architecture de fusion et concentrer la capacite sur l’exploitation directe des representations de contenu.

Amazon Fashion n’a pas ete entraine. Le pretraitement est complet, mais l’encodage des 23 033 items de ce jeu represente environ trois heures de calcul sur notre hote CPU et n’a pas ete mene a terme. Les conclusions portant sur deux jeux de donnees, elles resteraient a confirmer sur ce troisieme jeu.

Ces limites n’alterent pas le resultat principal : sur Amazon Beauty, LLM-SEMREC obtient la meilleure performance sur les trois metriques, bat significativement tous les baselines, et l’avantage est maximal precisement sur les items froids, ou les modeles par identifiants echouent completement.




Figure 13: Complexite de calcul sur une machine sans GPU. (a) Nombre de parametres entrainables par modele. (b) Latence d’inference pour 256 utilisateurs en fonction de la longueur maximale d’historique L . (c) Temps d’entrainement par epoque.

Table 7: Test t apparie bilateral sur le Hit@10 par utilisateur, LLM-SEMREC contre chaque baseline. p est la valeur brute, p_{adj} la valeur corrgee par Bonferroni.

Jeu de donnees	Baseline	p	Conclusion
Beauty	BPR-MF	$2,6 \times 10^{-3}$	significatif
	SASRec	$1,1 \times 10^{-21}$	significatif
	BERT4Rec	$3,3 \times 10^{-13}$	significatif
	MM-SASRec	$2,3 \times 10^{-14}$	significatif
	LLM-only	$1,5 \times 10^{-14}$	significatif
	GRU4Rec	$1,9 \times 10^{-80}$	significatif
	Caser	$3,6 \times 10^{-82}$	significatif
MovieLens-1M	BPR-MF	0,30	non significatif
	LLM-only	0,29	non significatif
	MM-SASRec	$6,7 \times 10^{-3}$	significatif
	BERT4Rec	$5,6 \times 10^{-4}$	significatif
	SASRec	$1,8 \times 10^{-4}$	significatif
	MMSSL-lite	$1,0 \times 10^{-4}$	significatif